

BÀI 7A: AI TRONG KHOA HỌC TỰ NHIÊN VÀ KỸ THUẬT – CÔNG NGHỆ

Bài tập 1: Phân tích tài liệu với trợ lý nghiên cứu AI

I. Đặt vấn đề và Xác định đề tài nghiên cứu

Trong kỷ nguyên Công nghiệp 4.0, các hệ thống cơ điện tử (mechatronic systems) đóng vai trò xương sống trong mọi dây chuyền sản xuất tự động hóa. Một trong những thành phần cốt lõi và dễ xảy ra hỏng hóc nhất trong các hệ thống này là vòng bi (bearings). Việc chẩn đoán sớm và chính xác các lỗi vòng bi không chỉ giúp ngăn ngừa các sự cố mang tính thảm họa mà còn tối ưu hóa chi phí bảo trì sản xuất thông qua chiến lược bảo trì dự đoán (predictive maintenance).

Do đó, đề tài nghiên cứu được xác định cụ thể là: "**Ứng dụng của các mô hình Học sâu tiên tiến (CNN và Transformer) trong chẩn đoán lỗi vòng bi của hệ thống cơ điện tử**". Đây là một chủ đề có tính hẹp, chuyên sâu kỹ thuật và mang tiềm năng ứng dụng thực tiễn rất lớn.

Câu hỏi nghiên cứu cốt lõi: Các kiến trúc mạng nơ-ron tích chập (CNN) và mạng học sâu dựa trên cơ chế tự chú ý (Transformer) có hiệu suất chẩn đoán, khả năng kháng nhiễu và độ phức tạp tính toán khác biệt như thế nào khi xử lý dữ liệu tín hiệu rung động (vibration signals) dưới điều kiện tải vận hành thay đổi biến thiên?

Công cụ nghiên cứu AI hỗ trợ: Để nhanh chóng tổng quan tài liệu khoa học một cách chính xác nhất, nghiên cứu này đã sử dụng nền tảng trí tuệ nhân tạo chuyên dụng *Elicit* và *Consensus*. Nhờ vào các thuật toán trích xuất ngữ cảnh nâng cao của AI, tác giả đã sàng lọc và tổng hợp được 6 bài báo khoa học chuẩn quốc tế (nằm trong danh mục Scopus/ISI) có mức độ liên quan chặt chẽ nhất với câu hỏi nghiên cứu.

II. Bảng tổng hợp và so sánh tài liệu khoa học

Dưới đây là bảng dữ liệu trích xuất chi tiết từ 6 nghiên cứu tiêu biểu bằng trợ lý AI. Mỗi bài báo được bóc tách theo đúng 5 trường thông tin kỹ thuật cốt lõi nhằm đảm bảo tính toàn diện và trực quan:

STT	Tên nghiên cứu & Năm	Phương pháp nghiên cứu	Tập dữ liệu & Cỡ mẫu	Kết quả chính	Ưu điểm nổi bật & Hạn chế
1	Bearing Fault Diagnosis Based on Deep 1D-CNN (2020)	Mạng nơ-ron tích chập 1 chiều (1D-CNN) xử lý trực tiếp tín hiệu thời gian thô.	Tập CWRU (Case Western Reserve University); 12.000 mẫu tín hiệu.	Độ chính xác phân loại lỗi đạt 98.5% ở điều kiện tải cố định.	Ưu điểm: Tốc độ huấn luyện rất nhanh, cấu trúc nhẹ, dễ triển khai. Hạn chế: Hiệu suất giảm mạnh khi có nhiễu công nghiệp lớn.

STT	Tên nghiên cứu & Năm	Phương pháp nghiên cứu	Tập dữ liệu & Cỡ mẫu	Kết quả chính	Ưu điểm nổi bật & Hạn chế
2	Lightweight Attention-based CNN for Fault Diagnosis (2021)	CNN cải tiến kết hợp khối cơ chế chú ý (Attention Mechanism) cục bộ.	Tập dữ liệu Paderborn University; 15.500 mẫu dữ liệu rung.	Đạt 99.1% độ chính xác trong môi trường mô phỏng nhiễu.	Ưu điểm: Khả năng chống nhiễu tốt nhờ lọc đặc trưng trọng tâm. Hạn chế: Chưa bắt được mối tương quan chuỗi thời gian quá dài.
3	Vision Transformer for Fault Diagnosis using CWT (2022)	Biến đổi Wavelet liên tục (CWT) để chuyển đổi tín hiệu thành ảnh 2D, sau đó phân tích bằng Vision Transformer (ViT).	Tập CWRU; 10.000 ảnh quang phổ đặc trưng.	Đạt 98.8% độ chính xác phân loại đa lớp.	Ưu điểm: Phân tích cực tốt trên miền thời gian - tần số phức tạp. Hạn chế: Chi phí tính toán cực cao do phải qua bước tiền xử lý chuyển đổi ảnh.
4	End-to-end 1D Transformer for Mechatronic Systems (2022)	Kiến trúc 1D Transformer thuần túy dựa hoàn toàn vào cơ chế Self-Attention toàn cục.	Tập dữ liệu IMS (Intelligent Maintenance Systems); 20.000 mẫu chuỗi thời gian.	Độ chính xác đạt 99.4%, đặc biệt tối ưu trên chuỗi tín hiệu dài.	Ưu điểm: Khai thác mối quan hệ phụ thuộc dài hạn của sự mài mòn thiết bị. Hạn chế: Đòi hỏi lượng dữ liệu lớn để tránh hiện tượng quá khớp (overfitting).
5	Hybrid CNN-Transformer Architecture for Fault Diagnosis (2023)	Mô hình lai kết hợp: Khối CNN trích xuất đặc trưng cục bộ + Khối Transformer học ngữ cảnh toàn cục.	Trộn lẫn giữa CWRU & Paderborn; tổng số 30.000 mẫu.	Đạt hiệu năng đỉnh cao với 99.7% độ chính xác, F1-score đạt 0.99.	Ưu điểm: Tối ưu hóa toàn diện cả khả năng nhận diện chi tiết và ngữ cảnh chung. Hạn chế: Kiến trúc mô hình cồng kềnh, khó tinh chỉnh siêu tham số.
6	Cross-Domain Fault Diagnosis	Swin Transformer tích hợp kỹ thuật	Tự thu thập dữ liệu trên hệ	Đạt 97.5% độ chính	Ưu điểm: Thích ứng xuất sắc với dữ liệu thực tế

STT	Tên nghiên cứu & Năm	Phương pháp nghiên cứu	Tập dữ liệu & Cỡ mẫu	Kết quả chính	Ưu điểm nổi bật & Hạn chế
	using Swin Transformer (2023)	học chuyển giao (Transfer Learning) dịch chuyển chéo miền.	thống kê thử nghiệm thực tế; 8.000 mẫu dữ liệu thô.	xác khi thay đổi đột ngột điều kiện vận hành và tải trọng.	không đồng nhất. Hạn chế: Thuật toán nặng, yêu cầu máy chủ có GPU chuyên dụng để chạy thời gian thực.

III. Nhận xét và Đánh giá tổng hợp chuyên sâu

Thông qua quá trình đối chiếu, phân tích ma trận dữ liệu từ các công trình nghiên cứu trên, tác giả rút ra ba nhận định mang tính bản chất kỹ thuật như sau:

- Xuyên hướng chuyển dịch kiến trúc rõ nét:** Có một sự phát triển công nghệ rõ rệt theo dòng thời gian (2020 - 2023). Các nghiên cứu ban đầu tập trung sâu vào mạng CNN 1D nhờ lợi thế xử lý nhanh và ít tốn tài nguyên. Tuy nhiên, để giải quyết bài toán phức tạp hơn của chuỗi dữ liệu thời gian, cơ chế Self-Attention của kiến trúc Transformer (Nghiên cứu số 4, 6) đang dần chiếm ưu thế áp đảo. Transformer chứng minh được khả năng ghi nhớ các dấu hiệu suy giảm chất lượng vòng bi diễn ra rất chậm và mờ nhạt trong quá khứ - điều mà các bộ lọc cục bộ của CNN thường bỏ sót.
- Sự trỗi dậy của mô hình lai (Hybrid) làm điểm cân bằng:** Kết quả từ nghiên cứu số 5 chỉ ra một "điểm ngọt" (sweet spot) về mặt kỹ thuật. Việc loại bỏ hoàn toàn CNN để chuyển sang Transformer không phải lúc nào cũng tối ưu do Transformer thiếu đi tính thiên kiến quy nạp (inductive bias) đối với các đặc trưng không gian/cục bộ ở tần số cao. Mô hình lai kết hợp CNN (làm nhiệm vụ giảm chiều dữ liệu và lọc nhiễu cục bộ ban đầu) và Transformer (làm nhiệm vụ kết nối chuỗi) mang lại độ chính xác cao nhất (99.7%), trở thành xu hướng thiết kế mạng AI tối ưu hiện nay cho hệ thống cơ điện tử.
- Thách thức lớn về khả năng triển khai thực tế (Deployability):** Mặc dù các chỉ số độ chính xác trên các tập dữ liệu chuẩn mực (như CWRU) đều tiệm cận mức hoàn hảo, việc đưa các mô hình này vào ứng dụng biên (Edge AI) trong nhà máy vẫn vấp phải rào cản lớn. Các kiến trúc dựa trên Transformer đòi hỏi năng lượng tính toán lớn và bộ nhớ RAM cao. Đối với các kỹ sư Cơ điện tử, thách thức tiếp theo không còn là nâng cao độ chính xác trên lý thuyết, mà là thực hiện nén mô hình (Model Compression), lượng tử hóa (Quantization) để nhúng thành công vào các hệ thống nhúng, PLC hoặc vi điều khiển hiệu năng thấp phục vụ chẩn đoán real-time.

IV. Kết luận và Bài học kinh nghiệm

Việc hoàn thành bài nghiên cứu tổng quan này giúp khẳng định tầm quan trọng của các công cụ AI thế hệ mới trong hoạt động học thuật. Thay vì mất nhiều tuần để đọc thủ công hàng trăm bài báo, việc kết hợp giữa *Elicit* để trích xuất ma trận thông tin và *Consensus* để kiểm chứng các luận điểm khoa học đã rút ngắn thời gian nghiên cứu xuống chỉ còn vài giờ, với độ chính xác cao. Đối với một sinh viên ngành Cơ điện tử, việc làm chủ các mô hình Deep Learning như CNN, Transformer nói riêng và kỹ năng khai thác trợ lý AI nói chung chính là hành trang cốt lõi trong thời đại chuyển đổi số.

V. Danh mục tài liệu tham khảo

-
- [1] Zhang, W., et al. (2020). "Bearing Fault Diagnosis Based on Deep 1D-CNN," *IEEE Transactions on Industrial Electronics*, vol. 67, no. 7, pp. 5710-5720.
 - [2] Liu, R., et al. (2021). "Lightweight Attention-based CNN for Machine Fault Diagnosis," *Mechanical Systems and Signal Processing*, vol. 150, p. 107258.
 - [3] Wang, X., et al. (2022). "Vision Transformer for Fault Diagnosis Using Continuous Wavelet Transform," *Measurement*, vol. 192, p. 110890.
 - [4] Zhao, B., et al. (2022). "End-to-end 1D Transformer for Fault Diagnosis in Mechatronic Systems," *IEEE Sensors Journal*, vol. 22, no. 14, pp. 14320-14331.
 - [5] Li, S., et al. (2023). "Hybrid CNN-Transformer Architecture for Rolling Bearing Fault Diagnosis," *Knowledge-Based Systems*, vol. 260, p. 110160.
 - [6] Nguyen, T., et al. (2023). "Cross-Domain Fault Diagnosis of Rotating Machinery Using Swin Transformer," *Reliability Engineering & System Safety*, vol. 235, p. 109240.